

所有者優先権を保証する学内GPU共有基盤 の提案とユーザ参加行動の評価

下西研究室 櫻井 翔琉



Shimonishi Lab.

The University of Osaka

GPUの需要増加

AI・データサイエンス分野の発展に伴い、GPU需要は年々増加している。
特にデータセンター向けGPU市場は、今後も高い成長率で拡大すると予測されている¹。

GPU資源の高価さ・調達困難性


高性能GPUは製造コストが高く、またAI用途の需要集中により供給が逼迫している²。
→ 研究機関や大学において、必要な時に十分なGPU資源を確保することは困難。

学内GPU共有基盤 「Air Computing Pool」を検討

[1] Precedence Research, AI Data Center GPU Market Size Report, 2024.

[2] PC Gamer, AI demand is keeping GPU and memory prices high, 2024.

“Air Computing Pool”とは



目的：「ACP」の普及と持続的な運用


GPUを保有するユーザー同士の**新しい形態の共有サービス**において、普及・持続が可能となる運用ルールを構築すること。

提供者＝利用者

ACPの普及・持続には、システム内に多くの計算資源が必要


→従来のGrid Computingのような**善意による提供**ではなく、ユーザーが**自発的に資源を提供するインセンティブ**の設計。

課題：高性能なGPUの提供者が参加しにくい



提供者の利便性を最優先で保証する運用ルールが必要

所有者優先権を保証するプリエンティブ方式 を用いた学内GPU共有基盤



共有基盤をモデル化し、各運用ルールのパフォーマンス比較を行う

各ユーザーはタスク発生時に、全 GPUの中から**自身のターンアラウンドタイム (TAT) を最小化できる GPU**を動的に選択する

① 共有なし

各ユーザーが自分のGPUのみを使用する

② FCFS（先着順）方式

全員がACP上の全GPUを平等に利用

③ 所有者優先方式

自分のGPUを使う場合は、割り込んで優先して使える（他人のGPUは、FCFS）

④ プリエンプティブ方式

自分のGPUを使う場合は、他人のタスクを途中切断（他人のGPUは、FCFS）
途中切断されたタスクはマイグレーション or 待機

待ち行列モデルによるシミュレーション

- ユーザー数：**18人**（GPUサーバ各1台）
- GPU性能：**9段階**
- タスク到着率：0.005[tasks/s]
→ **平均200秒に1回**

総シミュレーション時間：**24時間**

タスク：YOLOv7学習タスクを想定


- 画像1枚当たり平均**0.360TFLOPs**
- エポック数：**10[回]**（均一）
- バッチサイズ[枚]を調節することでシステム全体の**負荷率**を操作

GPU名	性能 (TFLOPS)
GTX 1650	2.98
GTX 1080	8.87
RTX 3050	20.41
RTX 3060Ti	64.83
RTX 2080	82.60
RTX 2080Ti	110.00
Titan RTX	180.50
RTX 4070	233.00
A100	311.84

シミュレーション結果：シナリオ別全体平均TAT


非共有よりどの共有
シナリオもTATが
大幅に短縮

負荷率0.8まではプリエ
ンティブが最小
0.8以降逆転



FCFS、所有者優先
方式は非共有より
TATが大

プリエンティブ方式
は同水準



待ち時間を効用式とした意思決定モデルと参加者数の推移評価

合理的なユーザー行動のモデル化

各ユーザーは「タスクの平均完了時間」の速さのみを基準に、ACPへの参加・不参加を自律的に判断すると想定。

参加判断のロジック 毎ループごとに参加判断

未参加者：「現在のACPに自分が加わった場合」の待ち時間を予測し、自分のGPUのみを使う場合と比較して早い方を選択。


参加者：「現在のACPでの実績値」と、自分一人で計算した場合を比較し、継続か離脱かを判断。

持続性の評価指標



初回をランダム参加とし、10回のループを通じて、性能別のユーザーが最終的にどれだけACPに定着するかを評価。

シミュレーション結果：参加者数推移

「FCFS」、「所有者優先」
では中性能・高性能
ユーザーは最終的に不参加




「プリエンプティブ方式」
では全員参加



負荷率にともなう各シナリオ最終参加者数

全負荷率において高い
参加者数を維持している



研究の成果

- ACPを導入することで、低性能ユーザは**大幅に待ち時間が減少**
- 高性能ユーザは、プリエンプティブ方式によって自GPUの優先権を保ちつつ、他GPUも利用することで待ち時間が減少
- プリエンプティブ方式という**技術的なアプローチのみ**によって、タスクの処理効率が上がり、ユーザの参加インセンティブにつながった

今後の展望

- タスクの与え方や複数台GPUなどのより研究室の環境を再現して**現実的なモデルの構築**
- タスク集中による電力コストやフリーライダー問題を考慮に入れ、ポイント制などの**経済的なインセンティブの導入**